

2.1 概率论基本概念

2.1.1 概率 $P(A) \geq 0$ $P(\Omega) = 1$ $P(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$

2.1.2 最大似然估计 用频率作为概率的估计值

样本空间 $\{s_1, s_2, \dots, s_n\}$

样本 $(s_i, 1 \leq i \leq n)$ 的次数是 $n(s_i)$, 那么, s_i 在这 n 次试验中的

相对频率为 $q_n(s_i) = \frac{n(s_i)}{n}$

n 越来越大时, $\lim_{n \rightarrow \infty} q_n(s_i) = P(s_i)$

2.1.3 条件概率

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

一般形式为 $P(A_1 A_2 \dots A_n) = P(A_1) P(A_2|A_1) \frac{P(A_3) P(A_4)}{P(A_1 A_2)} \dots P(A_n | \bigcap_{i=1}^{n-1} A_i)$

2.1.4 贝叶斯法则

$$P(B|A) = \frac{P(A \cap B)}{P(A)} = \frac{P(A|B) P(B)}{P(A)}$$

将 $P(A)$ 看作普通变量

$$\arg \max_B \frac{P(A \cap B)}{P(A)} = \arg \max_B P(A|B) P(B)$$

$\arg \max$ 代表求使后面的值最大的参数

事件 A 的概率计算法

$$P(A \cap B) = P(A|B) P(B)$$

$$P(A \cap \bar{B}) = P(A|\bar{B}) P(\bar{B})$$

$$\text{因此 } P(A) = P(A \cap B) + P(A \cap \bar{B}) = P(A|B) P(B) + P(A|\bar{B}) P(\bar{B})$$

推广: 假设 B 是样本空间 Ω 的一个划分, 即 $\sum B_i = \Omega$

如果 $A \subseteq \sum B_i$, 并且 B_i 互不相交, 那么 $A = \sum B_i A$

$$\text{即 } P(A) = \sum P(B_i A)$$

$$\text{即 } P(A) = \sum P(A|B_i) P(B_i)$$

全概率公式



给出贝叶斯法则的精确描述:

假设 A 为样本空间 Ω 的事件, B_1, B_2, \dots, B_n 为 Ω 的一个划分, 如果 $A \subseteq \bigcup_{i=1}^n B_i$, $P(A) > 0$ 并且 $B_i \cap B_j = \emptyset$, $P(B_i) > 0$ ($i=1, 2, \dots, n$) 则

$$P(B_j|A) = \frac{P(A|B_j)P(B_j)}{P(A)} = \frac{P(A|B_j)P(B_j)}{\sum_{i=1}^n P(A|B_i)P(B_i)}$$

例 2-1. G : 确实使用 T : 判断使用
求 $P(G|T)$ 已知: $P(T|G)$ $P(G)$
求 $P(T)$

$$P(T) = P(T|G) + P(T|\bar{G})$$

2.1.5 随机变量

设 x 为一离散型随机变量, 其全部可能的值为 $\{a_1, a_2, \dots\}$ 则

$$P_i = P(X = a_i), i=1, 2, \dots \text{ 称为 } x \text{ 的概率函数}$$

分布函数: $P(X \leq x) = F(x)$, $-\infty < x < \infty$

分布函数 $F(x)$ 在 x 处的函数值就表示 x 落在 $(-\infty, x)$ 上的概率。

2.1.6 二项式分布

$$P_i = C_n^i p^i (1-p)^{n-i} \quad x \sim B(n, p)$$

独立重复试验

[在自然语言处理中, 一般以句子为处理单位, 为了解决问题, 通常假设一个句子的出现独立于它前面的其他句子, 句子的概率分布近似地被认为是独立分布]

2.1.7 联合概率分布和条件概率分布

(X_1, X_2) 的联合分布为 $P_{ij} = P(X_1 = a_i, X_2 = b_j)$, $i=1, 2, \dots, j=1, 2, \dots$

考虑 X_1 在给定 $X_2 = b_j$ 条件下的概率分布, 其实就是求条件概率 $P(X_1 = a_i | X_2 = b_j)$

$$\text{即 } P(X_1 = a_i | X_2 = b_j) = \frac{P(X_1 = a_i, X_2 = b_j)}{P(X_2 = b_j)} = \frac{P_{ij}}{P(X_2 = b_j)} = \frac{P_{ij}}{\sum_i P_{ij}}$$

2.1.8 贝叶斯决策理论



假设所见的分类问题有 c 个类别, 各类别的状态用 w_i 表示.

先验概率: $p(w_i)$ (特征: 对称的表述)

在特征空间 \mathcal{X} 中任意某一点 $x = [x_1, x_2, \dots, x_d]^T$ 是 d 维特征空间上的某一点.
条件概率密度函数 $p(x|w_i)$

可得后验概率 $p(w_i|x)$ 如下:

$$p(w_i|x) = \frac{p(x|w_i)p(w_i)}{\sum_{j=1}^c p(x|w_j)p(w_j)}$$

基于最小错误率的贝叶斯决策规则为:

如果 $p(w_i|x) = \max_{j=1,2,\dots,c} p(w_j|x)$, 那么 $x \in w_i$

如果 $p(x|w_i)p(w_i) = \max_{j=1,2,\dots,c} p(x|w_j)p(w_j)$, 那么 $x \in w_i$

如果 $c=2$, 且 $\lambda(x) = \frac{p(x|w_1)}{p(x|w_2)} > \frac{p(w_2)}{p(w_1)}$, 则 $x \in w_1$, 否则 $x \in w_2$

其中 $\lambda(x)$ 称为似然比, 而 $\frac{p(w_2)}{p(w_1)}$ 称为似然比值

2.1.9 期望和方差

$$E(X) = \sum_{k=1}^{\infty} x_k p_k$$

$$\text{Var}(X) = E((X - E(X))^2) = E(X^2) - E^2(X)$$

